

Нерешенные проблемы и новые направления

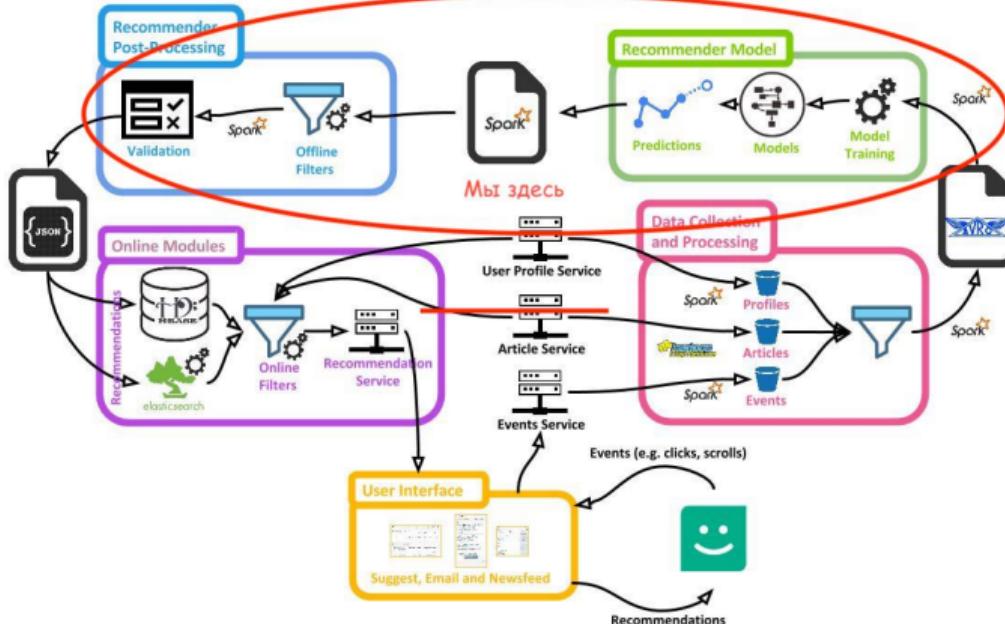
Николай Анохин

28 октября 2021 г.

Программа модуля

Дата	Тема	Семинар	Домашка
2021-09-30	Рекомендательные сервисы в продакшене	✓	
2021-10-07	Метрики и базовые подходы	✓	
2021-09-14	Классические алгоритмы рекомендаций	✓	✓
2021-09-21	Нейросетевые рекомендеры	✓	
2021-09-28	Нерешенные проблемы и новые направления	✓	

Контекст



Что мы уже умеем

$$\hat{r}_{ui} = f_{\theta}(x_u, x_i, x_c)$$

Разнообразие / Diversity



Набираем айтемы с разными аспектами

f - аспект (признак) айтема, $p(f|i)$ – вероятность найти аспект у айтэма i

Распределение аспекта у пользователя

$$p(f|u) = \frac{\sum_{i \in I_u} p(f|i)}{|I_u|}$$

Распределение аспекта в рекомендациях

$$q(f|u) = \frac{\sum_{i \in RL} p(f|i)}{|RL|}$$

Формируем список так, чтобы $q(f|u)$ совпало с $p(f|u)$

Жадное переранжирование

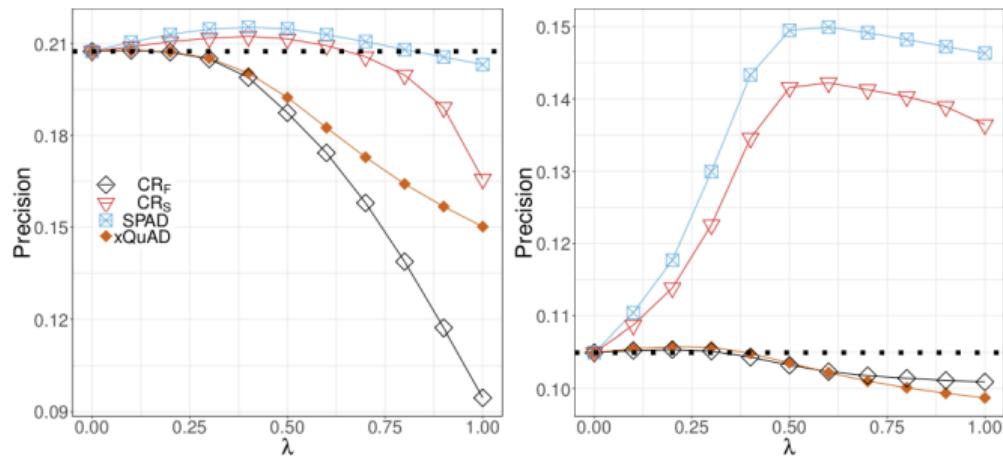
Добавляем в список рекомендаций айтем с максимальным значением

$$(1 - \lambda) \cdot s(u, i) + \lambda \cdot gain(i, RL),$$

пока не получим список нужной длины.

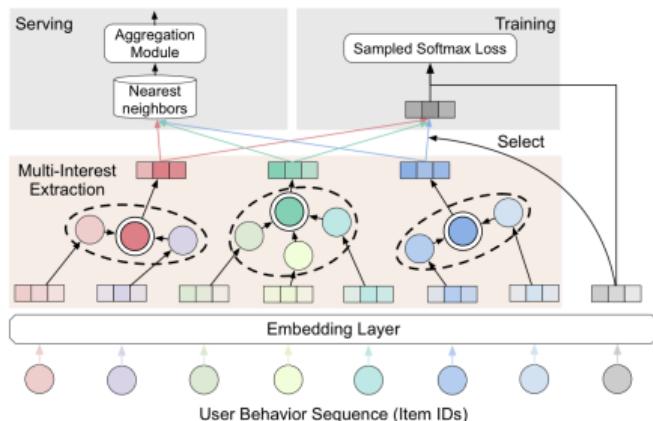
- $s(u, i)$ – релевантность айтема i для пользователя u
- $gain(i, RL) = div(RL \cup \{i\}) - div(RL)$ – улучшение разнообразия при добавлении айтема
- λ – гиперпараметр

A Comparison of Calibrated and Intent-Aware Recommendations [KB19]



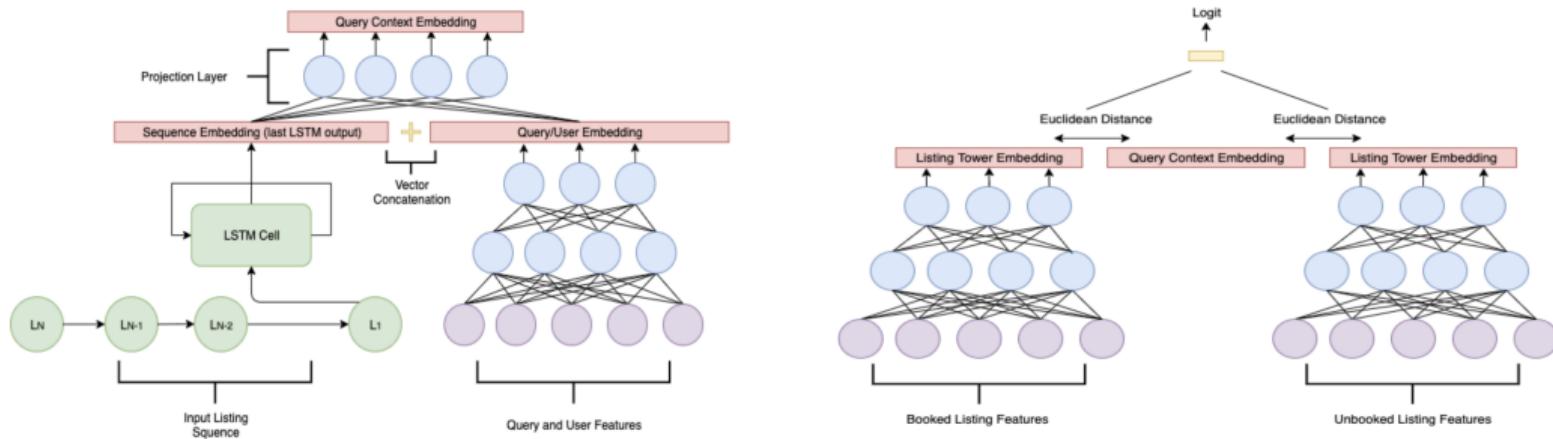
Учим разнообразие вместе с моделью 1

Controllable Multi-Interest Framework for Recommendation [CZZ⁺20]



Учим разнообразие вместе с моделью 2

Managing Diversity in Airbnb Search [AHR⁺20]

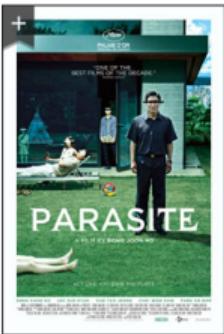


Пост-процессим предсказания модели, чтобы получить разнообразные рекомендации

Необходимость разнообразия можно обосновываем А/В тестом.

Объяснения

???

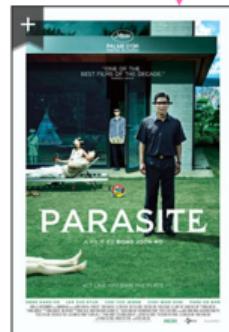


Объяснения

Потому что
вы оценили
Toy Story



Потому что вам
нравятся комедии



Популярное



Разнообразие в рекомендательных системах
oooooooo

Объяснение рекомендаций
ooo●oooooooo

Causal Recommenders
oooo

RL в рекомендациях
oooooo

Итоги
oooo

Зачем объяснять рекомендации?

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система
- Контролируемость: позволить пользователю исправить ошибки

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система
- Контролируемость: позволить пользователю исправить ошибки
- Доверие: убедить пользователя, что система работает правильно

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система
- Контролируемость: позволить пользователю исправить ошибки
- Доверие: убедить пользователя, что система работает правильно
- Убеждение: мотивировать пользователя к покупке

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система
- Контролируемость: позволить пользователю исправить ошибки
- Доверие: убедить пользователя, что система работает правильно
- Убеждение: мотивировать пользователя к покупке
- Полезность: помочь пользователю принять правильное решение

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система
- Контролируемость: позволить пользователю исправить ошибки
- Доверие: убедить пользователя, что система работает правильно
- Убеждение: мотивировать пользователя к покупке
- Полезность: помочь пользователю принять правильное решение
- Эффективность: помочь пользователю принять решение быстро

Зачем объяснять рекомендации?

- Прозрачность: объяснить пользователю, как работает система
- Контролируемость: позволить пользователю исправить ошибки
- Доверие: убедить пользователя, что система работает правильно
- Убеждение: мотивировать пользователя к покупке
- Полезность: помочь пользователю принять правильное решение
- Эффективность: помочь пользователю принять решение быстро
- Удовольствие: сделать приятно пользователю

Case-based

Because you have selected or highly rated: Movie A

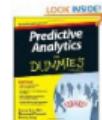
Потому что вы смотрели «ЛЕГО Фильм 2»



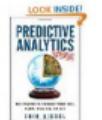
Collaborative

Customers Who Bought This Item Also Bought A

Customers Who Bought This Item Also Bought



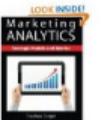
Predictive Analytics For Dummies
› Anasse Barri
★★★★★ 29
Paperback
\$17.72 ✓Prime



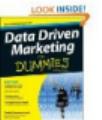
Predictive Analytics: The Power to Predict Who...
› Eric Siegel
★★★★★ 229
#1 Best Seller in Econometrics
Hardcover
\$16.88 ✓Prime



Quantifying the User Experience: Practical...
› Jeff Sauro
★★★★★ 8
Paperback
\$40.63 ✓Prime



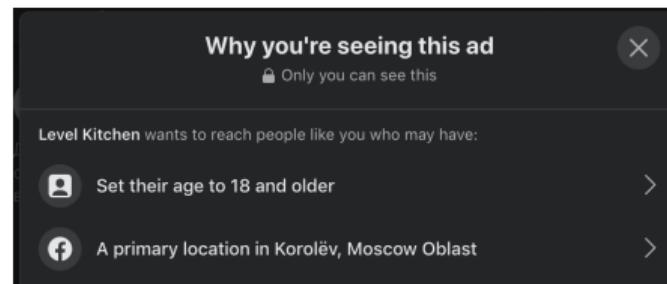
Marketing Analytics: Strategic Models and...
› Stephan Sorger
★★★★★ 29
Paperback
\$50.52 ✓Prime



Data Driven Marketing For Dummies
› David Semmelroth
Paperback
\$20.49 ✓Prime

Content-based

Recommended because you said you owned Book A



Knowledge-based

Less Memory and Lower Resolution and Cheaper



This item **Lenovo IdeaPad 3 14"** Laptop, Intel Core i3-1005G1 Processor, 4GB DDR4 RAM, 128GB M.2 SSD Storage, 14.0" FHD (1920 x 1080) Display, Integrated Graphics, Windows 10 S, 81WWD010QUS, Platinum Grey

[#1 Best Seller](#)[Add to Cart](#)

Lenovo IdeaPad 3 14 Laptop, AMD Ryzen 5 5500U Processor, 8GB DDR4 RAM, 256GB NVMe SSD Storage, 14.0" FHD (1920 x 1080) Display, AMD Radeon 7 Graphics, Windows 10 Home, 82KTD00AMUS, Abyss Blue

[Add to Cart](#)

Lenovo IdeaPad 1 14 14.0" Laptop, 14.0" HD (1366 x 768) Display, Intel Celeron N4020 Processor, 4GB DDR4 RAM, 64 GB SSD Storage, Intel UHD Graphics 600, Win 10 in S Mode, 81VU0079US, Ice Blue

[Add to Cart](#)

Lenovo IdeaPad Gaming 3 15 15.6" Laptop, 15.6" FHD (1920 x 1080) Display, AMD Ryzen 5 5600H Processor, NVIDIA GeForce GTX 1650, 8GB DDR4 RAM, 256GB SSD Storage, Windows 10H, 82K20015US, Shadow Black

[Add to Cart](#)

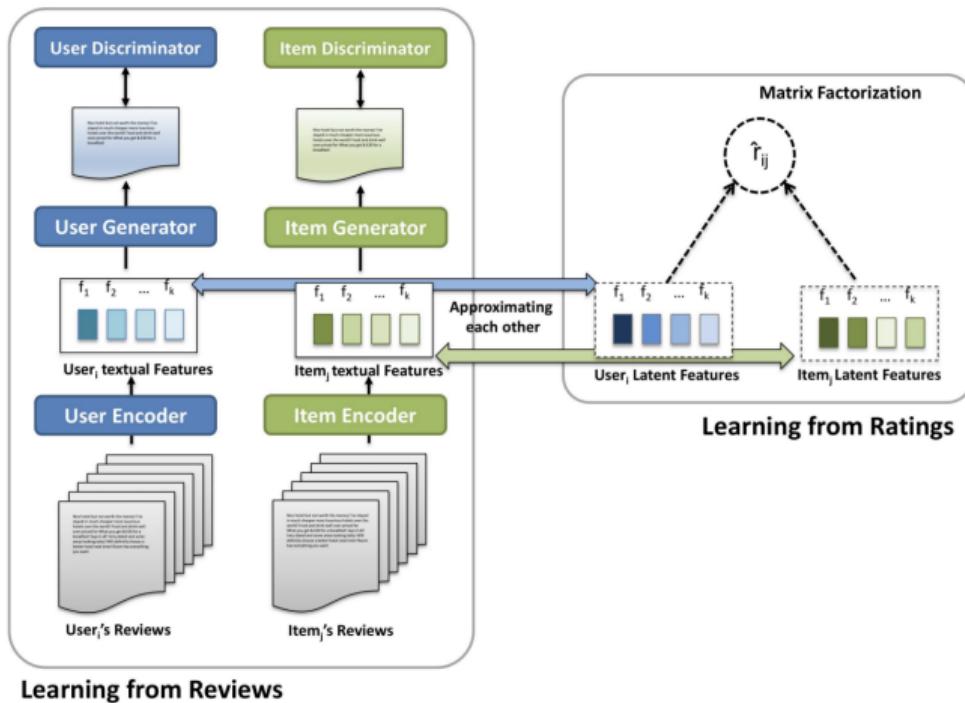
Customer Rating	★★★★☆ (32)	★★★★★ (118)	★★★★★ (590)	★★★★★ (134)
Price	\$399 ⁰⁰	\$539 ⁰⁰	\$266 ⁴²	\$769 ²²
Sold By	eSales Plus	Xocean	Mohawk Shop	ETRON INC - ELECTRONICS SUPPLIER
Computer Memory Size	128 GB	8	4	8
CPU Model Manufacturer	Intel	AMD	Intel	AMD
CPU Speed	1.2 GHz	2.1	1.1	3.3

Explore, Exploit, and Explain: Personalizing Explainable Recommendations with Bandits [MLH⁺18]

Explanation	# Impressions
Because it's [day of week]	140.3K
Inspired by [user]'s recent listening	138.4K
Because it's a new release	140.5K
Because [user] likes [genre]	130.7K
Because it's popular	140.5K
Mood	140.7K
Focus	140.5K

$$r(j, e, x) = \sigma(\theta_{global} + \theta_j \times 1_j + \theta_e \times 1_e + \theta_x \times 1_x)$$

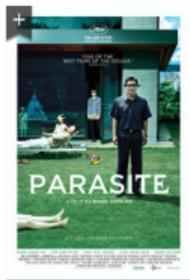
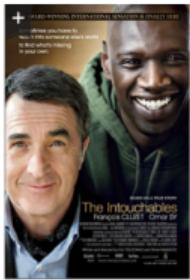
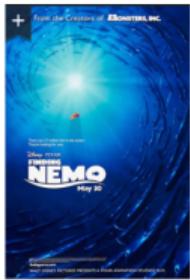
Why I like it: Multi-task Learning for Recommendation and Explanation [LDS18]



Если хотим делать объяснения рекомендаций, нужно ответить на вопросы:

- Какую цель мы достигнем объяснениями?
- Какие объяснения можно получить из модели?
- Как правильно представить объяснения пользователю?

Causal Recommenders



Традиционный рекомендер

Посмотрит ли пользователь этот фильм, если известно что она смотрела в прошлом?

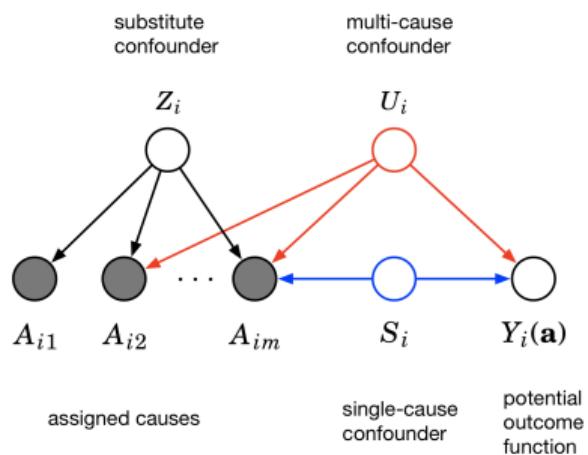
Causal рекомендер

Посмотрит ли пользователь этот фильм, если мы его порекомендуем, и известно, что она смотрела в прошлом?

The Deconfounded Recommender [WLCB18]

Confounder

Переменная, которая влияет и на treatment assignment, и на outcome



1. Учим модель $p(z, a_1, \dots, a_m)$
2. Оцениваем $E(z_j | a_{1j}, \dots, a_{mj})$ для каждого наблюдения
3. Используем оценки для z_j как признак в рекомендре

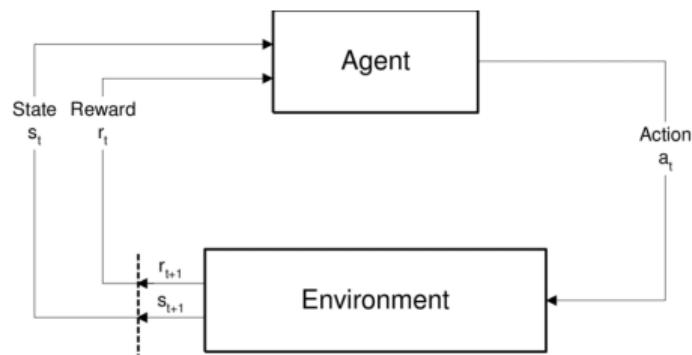
Прежде чем делать causal рекомендации, думаем как поставить эксперимент, измеряющий causal effect.

Долгосрочный эффект



Почему Reinforcement Learning?

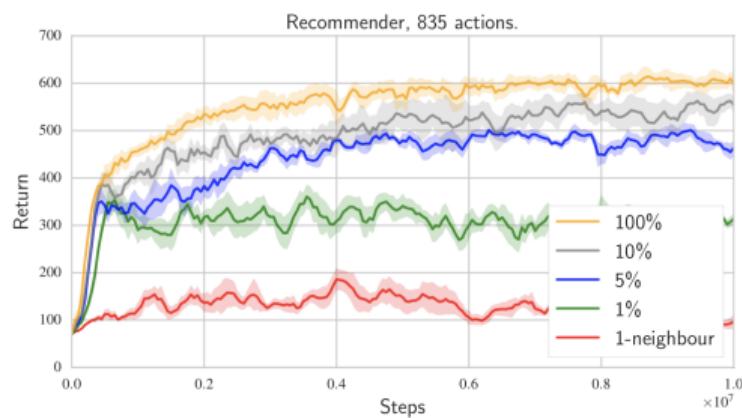
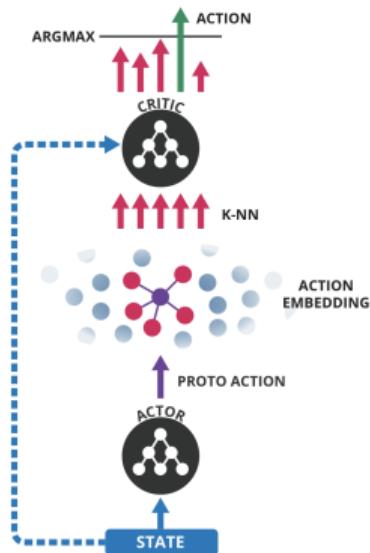
1. Feedback loop: рекомендер влияет на пользователя
2. Замыкание в пузыре и дилемма explore/exploit
3. Отложенная награда и долгосрочный эффект
4. Смещение между обучающими и продакшен данными



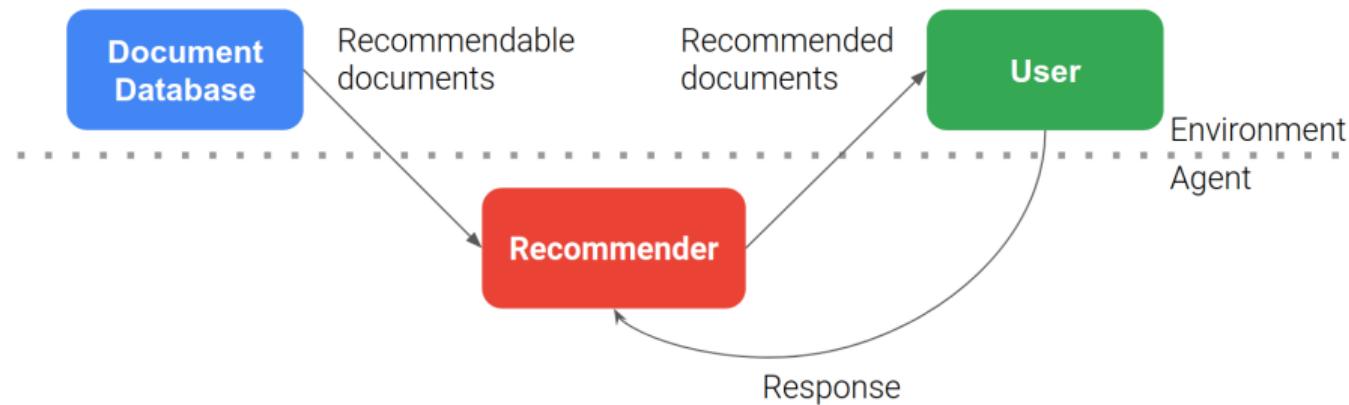
Где тогда Reinforcement Learning?

- Огромное количество действий
- Отсутствие сред для проверки идей
- Дорогая реализация алгоритмов

Deep Reinforcement Learning in Large Discrete Action Spaces [DAEH⁺15]



RecSim: A Configurable Simulation Platform for Recommender Systems [IHM⁺19]



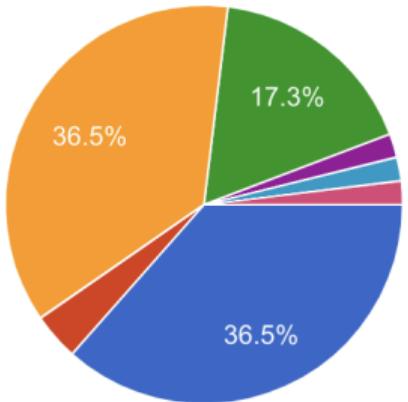
Придется подождать, пока RL в рекомендациях станет общей практикой.

Пока что привыкаем к вероятностным политикам и логируем вероятности.

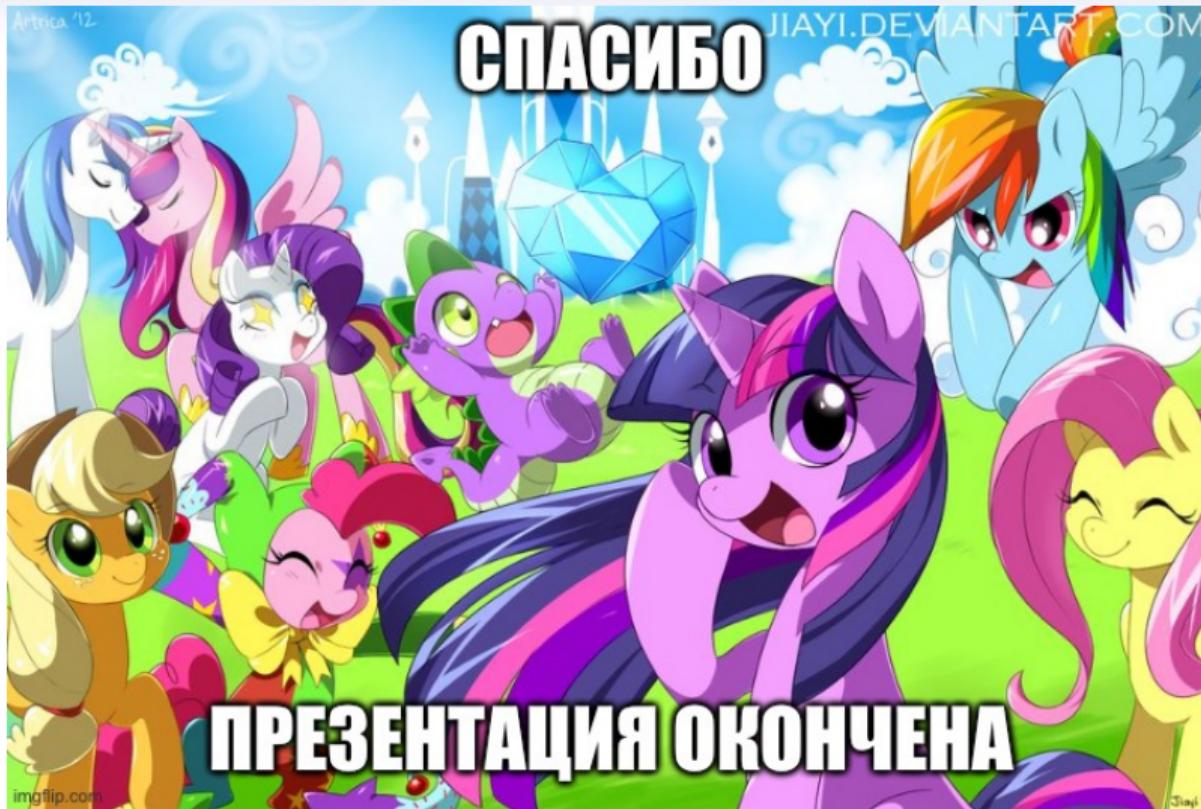
Итоги

В будущем рекомендательные системы будут давать релевантные, разнообразные и полезные рекомендации. Они будут учитывать долгосрочные интересы пользователей. А пользователи будут понимать, почему им что-то предлагают и смогут контролировать механизмы построения рекомендаций.

Но понадобится ваша помощь.



- Хочу получить базовое введение в рекомендательные сервисы
- Хочу получить глубокие теоретические знания о задаче реко...
- Хочу научиться создавать боевые рекомендательные сервисы
- Хочу просто пройти курс, это требуе...
- 1 и 3 пункт, 2 боюсь не вывезу
- Хочу посмотреть, как создаются бое...
- Хочется поиграться с рек. системам...



Не прощаюсь: дедлайн домашки 10 ноября 23:59 МСК

Литература I

-  Mustafa Abdool, Malay Haldar, Prashant Ramanathan, Tyler Sax, Lanbo Zhang, Aamir Manaswala, Lynn Yang, Bradley Turnbull, Qing Zhang, and Thomas Legrand, *Managing diversity in airbnb search*, Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (New York, NY, USA), KDD '20, Association for Computing Machinery, 2020, p. 2952–2960.
-  Yukuo Cen, Jianwei Zhang, Xu Zou, Chang Zhou, Hongxia Yang, and Jie Tang, *Controllable multi-interest framework for recommendation*, Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (2020).

Литература II

-  Gabriel Dulac-Arnold, Richard Evans, H. V. Hasselt, Peter Sunehag, Timothy P. Lillicrap, Jonathan J. Hunt, Timothy A. Mann, Théophane Weber, Thomas Degrif, and Ben Coppin, *Deep reinforcement learning in large discrete action spaces*, arXiv: Artificial Intelligence (2015).
-  Eugene le, Chih-wei Hsu, Martin Mladenov, Vihan Jain, Sanmit Narvekar, Jing Wang, Rui Wu, and Craig Boutilier, *Recsim: A configurable simulation platform for recommender systems*, 2019, cite arxiv:1909.04847.
-  Mesut Kaya and Derek Bridge, *A comparison of calibrated and intent-aware recommendations*, Proceedings of the 13th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '19, Association for Computing Machinery, 2019, p. 151–159.

Литература III

-  Yichao Lu, Ruihai Dong, and Barry Smyth, *Why i like it: Multi-task learning for recommendation and explanation*, Proceedings of the 12th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '18, Association for Computing Machinery, 2018, p. 4–12.
-  James McInerney, Benjamin Lacker, Samantha Hansen, Karl Higley, Hugues Bouchard, Alois Gruson, and Rishabh Mehrotra, *Explore, exploit, and explain: Personalizing explainable recommendations with bandits*, Proceedings of the 12th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '18, Association for Computing Machinery, 2018, p. 31–39.
-  Yixin Wang, Dawen Liang, Laurent Charlin, and David M. Blei, *The deconfounded recommender: A causal inference approach to recommendation*, ArXiv abs/1808.06581 (2018).